PRÁTICA PROFISSIONAL - INTELIGÊNCIA ARTIFICIAL E APRENDIZADO DE MÁQUINA

MODELO DE PREDIÇÃO DE PACIENTES COM PATOLOGIAS CARDÍACAS

Fabrício Evangelista Dos Santos - 202318390

Gabriel Junio Fernandes Pereira - 202325640

Lucas Kenzo Terazzin Ida - 202306868

Murilo Nogueira Minutti - 202303873

Pedro Henrique Almeida Lopes - 202309011

Prof. Felipe Cavalaro

Itatiba - 2026

Introdução

O conceito de inteligência artificial e aprendizado de máquina surgiu na década de 1950, proposto inicialmente por John McCarthy e outros especialistas da área de pesquisa. Desde então, foram descobertos diversos modelos, algoritmos e sistemas que trariam diversos benefícios e ganho de produtividade para a sociedade, mas por muitas décadas essas inovações foram limitadas por falta de capacidade computacional e quantidade de dados disponíveis.

Em 2026 esse cenário se encontra completamente diferente. Possuímos capacidades computacionais inimagináveis pelos especialistas na década de 1950, com uma quantidade nunca antes vista de dados.

Utilizando-se dessa evolução tecnológica, neste presente trabalho temos o objetivo de desenvolver um modelo de aprendizado de máquina capaz de prever se um paciente possui patologias cardíacas, através de 11 atributos clínicos provenientes de exames de saúde. Com esse modelo que será desenvolvido, poderemos auxiliar a área de saúde com um diagnóstico precoce, otimizando a eficácia do tratamento e o prognóstico do paciente.

O modelo a ser utilizado será de classificação binária, pois desejamos prever uma categoria (saudável/enfermo). Dentro dessa natureza, foram escolhidas duas famílias de classificação para avançar com o estudo: árvore de decisão e modelo probabilístico. A escolha dessas duas famílias foi pela natureza de modelagem serem de conceitos bastante distintos, assim nos permitindo uma análise e comparação mais interessante e aprofundada sobre as métricas dos modelos desenvolvidos.

Fundamentação Teórica

De acordo com Kühl et al. (2022), as definições recentes de Inteligência Artificial se dão pela habilidade das máquinas demonstrarem funções cognitivas associadas com a mente humana, como: percepção, raciocínio, aprendizado, interação com o ambiente, resolução de problemas, tomada de decisão e criatividade. Desses mesmos autores, é descrito que o Aprendizado de Máquina é uma parte exclusiva de Inteligência Artificial. Modelos de Aprendizado de Máquina imitam a habilidade cognitiva humana de possuir um conjunto de métodos usados comumente para resolver diversos problemas do mundo real e, com o auxílio de sistemas computacionais, resolver esses mesmos problemas sem que seja explicitamente programado para essa solução.

Utilizando-se da definição de Mienye e Jere (2024), a ideia básica por trás dos algoritmos baseados em árvore de decisão é a partição recursiva dos dados baseados nos valores definidos por diferentes atributos até que se encontre um critério de parada. Esse processo resulta em uma estrutura parecida com uma árvore, onde cada nó representa um critério de divisão. Cada algoritmo determina qual é o atributo que será utilizado para divisão em cada nó, como ganho de informação, taxa de ganho e índice de Gini.

As árvores de decisão são conhecidas pela sua interpretabilidade. A árvore resultante do algoritmo permite que qualquer um consiga entender o processo de decisão da classificação, sendo amplamente utilizado em áreas na qual cada decisão precisa de transparência e responsabilidade, como saúde e financeira.

Figura 1: Exemplo de uma árvore de decisão

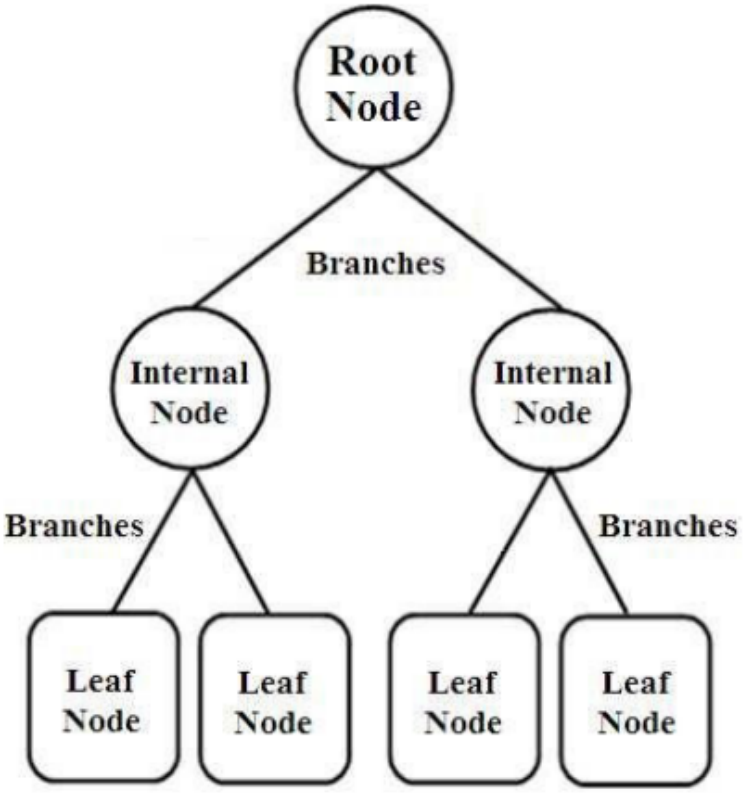

Fonte: Mienye e Jere (2024, p.2).

A figura 1 nos apresenta a estrutura de uma árvore de decisão:

- **Nó Raiz (Root Node)**: É o primeiro nó da árvore, momento onde todo o conjunto de dados estão agrupados.
- **Divisões (Branches)**: De acordo com os atributos definidos pelo algoritmo, é calculado qual o critério de divisão que melhor irá dividir esses dados, gerando novos nós.
- **Nó Interno (Internal Node)**: São os nós internos originados pelo nó pai, seguindo a mesma lógica de divisão dos nós anteriores, apresentando uma estrutura recursiva.
- **Folha (Leaf Node)**: Representa a classificação para aquele conjunto de dados. Ao chegar na folha, é retornado pelo algoritmo um valor binário, na qual é esperado pelo algoritmo.

O primeiro algoritmo selecionado para o nosso modelo de classificação é o ID3 (Iterative Dichotomiser 3), na qual utiliza o Ganho de Informação para estruturar a árvore de decisão. O Ganho de Informação é o atributo que mais reduz a entropia dos dados ao ser aplicado. Para entendermos o que são esses valores, deve ser conhecido a

seguinte fórmula para cálculo da entropia (desordem dos dados):

$$E(S) = -\sum_{i=1}^{n} p_i log_2(p_i)$$

Quanto mais balanceada a quantidade dos dados de cada classe, maior a entropia dos dados, sendo 1 o maior valor e 0 quando o dado está isolado apenas com uma classificação. Os atributos da árvore é ordenado com aqueles que mais reduzem a entropia sendo o nó raiz e, para definir qual atributo tem essa propriedade, é utilizado a seguinte fórmula para cálculo do Ganho de Informação:

$$IG = E(S) - \sum_{v \in Values(A)} \frac{|S_v|}{|S|} E(S_v)$$

Quanto maior o Ganho de Informação do atributo, mais capacidade de reduzir a entropia ele possui. Com esse cálculo, o algoritmo ID3 define a sua árvore.

Em conjunto com o algoritmo de árvore, foi selecionado um algoritmo com um fundamento distinto para que haja uma comparação de métricas, desempenho e assertividade mais interessante, sendo os algoritmos de probabilidade.

Conforme argumentado por Ghahramani (2015), os algoritmos de probabilidade são um dos algoritmos dos modelos de classificação, na qual é definido uma linha de corte (50%, por exemplo) e os valores acima ou abaixo dessa linha é classificado com 0 ou 1, conforme contexto do projeto. Dentro dos diversos modelos probabilísticos, vamos abordar a regressão logística, do motivo de serem adequados para o contexto do projeto.

Olowe et al. (2024) se aprofundou em seu artigo na aplicação da regressão logística na saúde. Algumas das principais vantagens desse modelo na área de saúde é pela possibilidade de validar quais são os atributos com maior influência na classificação do modelo, e pela possibilidade de não apenas retornar valores binários (doente ou não), mas ter acesso ao percentual de probabilidade do paciente ter ou não uma patologia (90% de chance de ter uma patologia é muito mais crítico do que 51%).

Nos modelos de regressão linear é importante que os atributos estejam normalizados. Na base de dados que será utilizada, por exemplo, existem dois tipos de atributos: contínuos e discretos. Os dados contínuos devem ser normalizados para que não tenha uma discrepância na importância de cada atributo, por meio de bibliotecas como *StandardScaler*, na qual permite normalizar entre 0 e 1.

Figura 2: Diferença entre regressão linear e logística

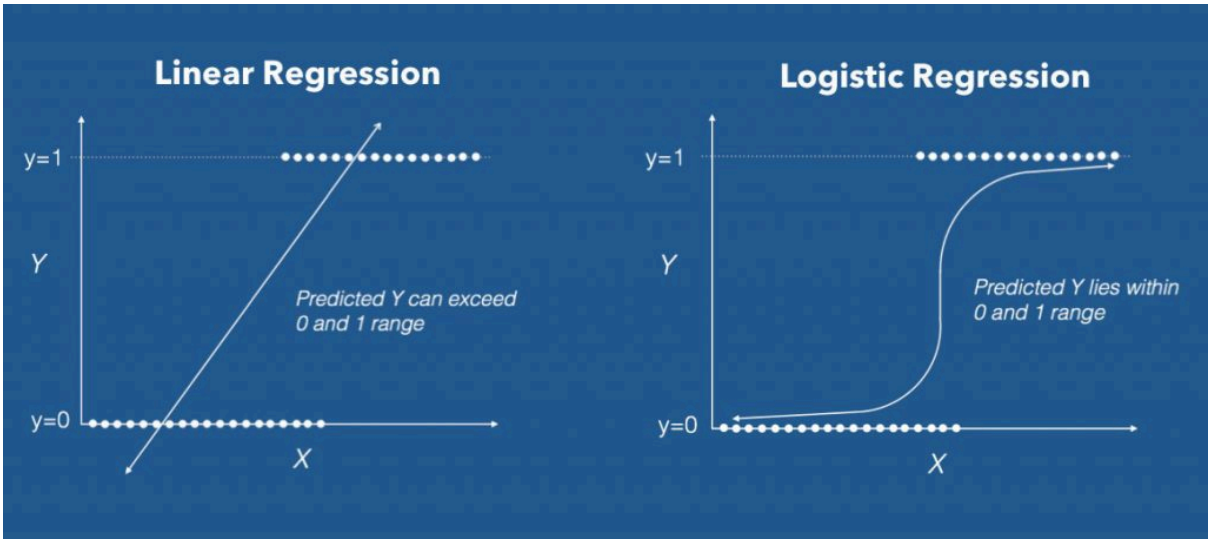

Fonte: MACHINE LEARNING PLUS. *Linear vs Logistic Regression*. 2021. Disponível em: https://machinelearningplus.com/wp-content/uploads/2021/06/linear_vs_logistic_regression-1024x454.jpg. Acesso em: 28 mar. 2026.

A regressão logística traça uma curva em S centralizando a linha de corte, onde ao lado direito é considerado como 1 e, esquerdo, como 0.

Esse modelo é considerado mais adequado nessa área delicada por não desconsiderar a correlação entre os atributos, diferente do algoritmo Naive Bayes, na qual considera que cada atributo não há uma correlação entre eles, sendo uma lógica não adequada quando se trata de cenários sensíveis, na qual é esperado uma interpretabilidade maior.

No scikit-learn, é utilizado a função de decisão (logito) para servir de base de cálculo:

$$z = X\omega + b$$

A fórmula é a combinação linear dos pesos (w) e do intercepto (b). Para converter o z em probabilidade, é aplicado a função logística padrão para gerar o sigmoide:

$$P(y = 1|x) = \frac{1}{1+e^{-z}}$$

Como critério de decisão, foi utilizado a linha de corte de 0.5:

$$\hat{y} = 1 \; se \; P(y = 1|x) \geq 0.5$$

$$\hat{y} = 0 \; se \; P(y = 1|x) \leq 0.5$$

Para refinar o modelo, é aplicado a regularização L2 por padrão, onde penaliza os pesos para evitar o overfitting:

$$J(\omega, b) = C \cdot LogLoss(\omega, b) + \frac{1}{2}||\omega||^2$$

Baseado nos modelos citados nos parágrafos acima, será possível comparar as métricas de cada algoritmo de diferentes modelos, verificando quais são as vantagens e desvantagens de cada um, comparando as métricas calculadas do resultado do treinamento.

Metodologia

- **Árvore de Decisão**

Foi adotado a Árvore de Decisão como um dos algoritmos de aprendizado de máquina para realizar a predição dos pacientes, utilizando o critério de entropia (baseado no algoritmo ID3) para medir o ganho de informação em cada nó. A grande vantagem desse modelo no contexto de saúde é a sua interpretabilidade, sendo um modelo caixa-branca.

Foi utilizado o dataset Heart Failure Prediction Dataset disponível no Kaggle, na qual disponibiliza atributos relevantes para essa predição como: tipo de dor no peito, resultados de ECG em repouso, angina induzida por exercício e inclinação do segmento ST. É um dataset com uma alta reputação pela comunidade da Kaggle pela consistência nos dados e aplicabilidade em modelos de aprendizado de máquina.

```
try:
  df = pd.read_csv('heart.csv')
  display(df.head())
except FileNotFoundError:
  print('Erro: falha ao abrir')
```

Foram utilizadas as bibliotecas Pandas e NumPy, dedicadas para manipulação dos dados, Matplotlib para visualizações e Scikit-learn para treinamento do modelo de aprendizado de máquina.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier, plot_tree
from sklearn.preprocessing import LabelEncoder
from  sklearn.metrics  import  accuracy_score,  classification_report,
confusion_matrix, ConfusionMatrixDisplay
```

Foi necessário aplicar uma transformação nas colunas categóricas textuais (sexo, tipo de dor no peito, etc) para valores numéricos por meio do LabelEncoder do Scikit-learn, para atender o requisito da entrada dos dados para implementação do DecisionTreeClassifier.

```
encoder = LabelEncoder()
categorical_cols = ['Sex', 'ChestPainType', 'RestingECG', 'ExerciseAngina', 'ST_Slope']

if 'df' in locals():
    for col in categorical_cols:
        df[col] = encoder.fit_transform(df[col])
    display(df.head())
```

Dividimos a proporção de 80% para treino e 20% para teste, utilizando o train_test_split, com random_state=42 para garantir que seja reproduzível. A divisão 80/20 é um padrão utilizado amplamente no mercado.

```
if 'df' in locals():
    X = df.drop(columns=['HeartDisease'])
    y = df['HeartDisease']
        X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
        print(f'Tamanho do conjunto de treino: {X_train.shape[0]} amostras')
    print(f'Tamanho do conjunto de teste: {X_test.shape[0]} amostras')
```

Foram calculadas as métricas de acurácia, precisão, recall e F1-score, para realizar uma avaliação completa do modelo, sem que seja enviesado em métricas pontuais. A avaliação completa das métricas permite uma maior confiabilidade, muito importante em contextos críticos como contexto clínico.

```
---Acurácia---
86.96%

---Relatorio de Classificação---
              precision    recall  f1-score   support

           0       0.84      0.86      0.85        77
           1       0.90      0.88      0.89       107

    accuracy                           0.87       184
   macro avg       0.87      0.87      0.87       184
weighted avg       0.87      0.87      0.87       184
```

Para aumentar a confiabilidade da avaliação, foi aplicada a validação cruzada k-Fold

com k=5. Essa técnica divide o dataset de treino em 5 partes, treinando e testando o modelo em combinações distintas, o que reduz o viés da divisão aleatória e fornece uma estimativa mais robusta do desempenho real do modelo.

```
[0.86956522 0.8423913  0.8423913  0.81420765 0.82513661]
Média das Pontuações de Acurácia: 0.8387
Desvio Padrão das Pontuações de Acurácia: 0.0188
```

Foram geradas a Matriz de Confusão — para análise visual dos acertos e erros por classe — e a visualização gráfica da árvore de decisão, exibindo os nós, critérios de divisão, valores de entropia e distribuição das amostras. Essas visualizações reforçam a interpretabilidade do modelo, permitindo compreender a lógica de classificação adotada.

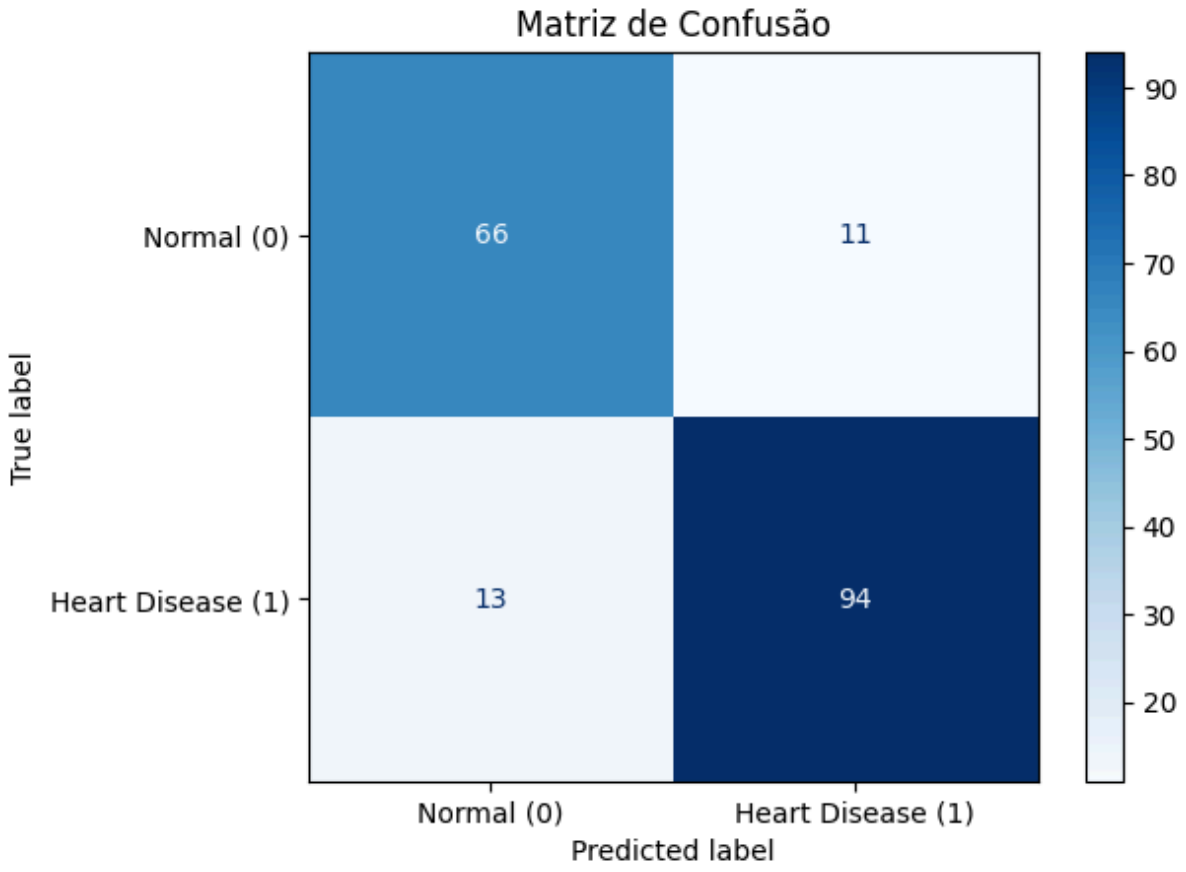

- **Regressão Logística**

Foi adotada a Regressão Logística como metodologia probabilística de classificação. A escolha foi por possuir uma abordagem diferente da árvore, possuindo conceitos e cálculos contrastantes, permitindo uma comparação dos resultados mais diversificada. Diferente do modelo de árvore, a regressão logística utiliza da função sigmoide para traçar um intervalo de probabilidade, não apenas rotulando a saída, mas informando sobre a probabilidade daquele resultado estar correto, sendo uma informação importante na área clínica.

Utilizou-se o mesmo Heart Failure Prediction Dataset do Kaggle, contendo atributos clínicos para predição de doenças cardíacas. A escolha do dataset se manteve consistente entre as modelagens para permitir comparação direta de desempenho entre os algoritmos.

```
df = pd.read_csv('heart.csv')
print(f'Shape: {df.shape}')
df.head()
```

Além das bibliotecas base Pandas, NumPy, Matplotlib e Scikit-learn, foi incorporada à biblioteca Seaborn para a geração da matriz de confusão com visualização mais refinada via heatmap. O Scikit-learn forneceu os módulos de pré-processamento (LabelEncoder, StandardScaler), modelagem (LogisticRegression) e avaliação de métricas.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder, StandardScaler
from sklearn.metrics import (
    accuracy_score,
    confusion_matrix,
    classification_report
)
```

As colunas categóricas foram identificadas automaticamente via select_dtypes e convertidas para valores numéricos com LabelEncoder. Uma etapa adicional em relação à modelagem em árvore foi a aplicação do StandardScaler, que padroniza os dados para média zero e desvio padrão unitário. Essa normalização é necessária na Regressão Logística porque o algoritmo é sensível à escala das variáveis, diferenças de magnitude entre atributos podem distorcer os coeficientes e prejudicar a convergência do modelo.

Os dados foram divididos em 80% para treino e 20% para teste, utilizando o

parâmetro stratify=y. O uso de estratificação garante que a proporção entre pacientes com e sem doença cardíaca seja preservada em ambos os conjuntos, evitando que um conjunto fique desbalanceado em relação ao outro.

```
cat_cols = df.select_dtypes(include='object').columns.tolist()
print(f'Colunas categóricas: {cat_cols}')

encoder = LabelEncoder()
df_encoded = df.copy()
for col in cat_cols:
    df_encoded[col] = encoder.fit_transform(df_encoded[col])

X = df_encoded.drop(columns=['HeartDisease'])
y = df_encoded['HeartDisease']

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

scaler = StandardScaler()
X_train_sc = scaler.fit_transform(X_train)
X_test_sc  = scaler.transform(X_test)

print(f'\nTreino: {X_train_sc.shape[0]} amostras | Teste:
{X_test_sc.shape[0]} amostras')
```

O modelo foi configurado com regularização L2 (penalty='l2', C=1.0) e o solver lbfgs, adequado para problemas de classificação binária com regularização L2. O parâmetro max_iter=1000 foi elevado acima do padrão para garantir a convergência do algoritmo diante da complexidade do dataset. A regularização L2 penaliza coeficientes muito grandes, contribuindo para a generalização do modelo e prevenindo o overfitting.

```
model = LogisticRegression(
    C=1.0,
    penalty='l2',
    solver='lbfgs',
    max_iter=1000,
    random_state=42
)

model.fit(X_train_sc, y_train)
```

O modelo foi avaliado com acurácia, precisão, recall e F1-score, além das probabilidades preditas (predict_proba), que permitem analisar o grau de confiança de cada classificação — não apenas se o paciente foi classificado corretamente, mas com qual nível de certeza.

Foram produzidas três visualizações complementares:

- **Matriz de Confusão** via heatmap do Seaborn, para análise dos acertos e erros por classe;

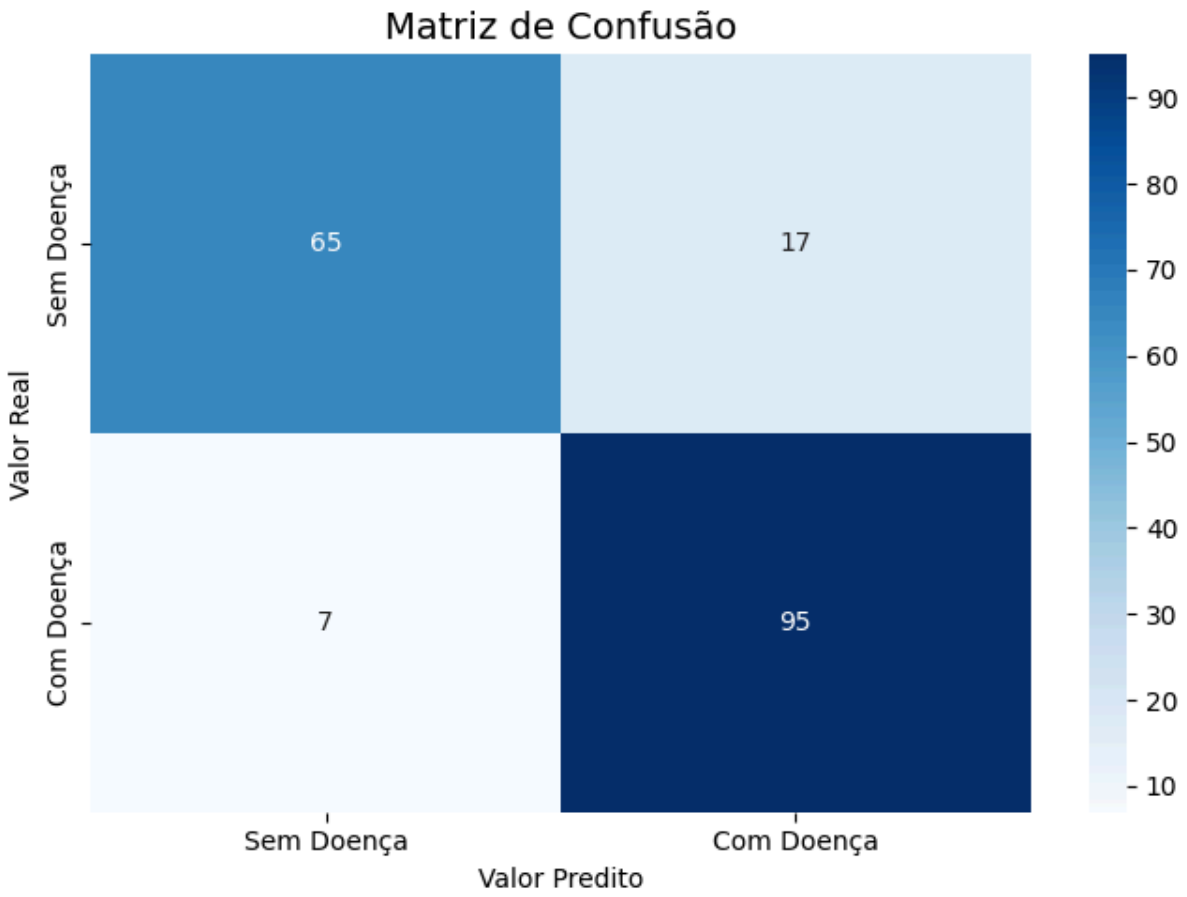

- **Função Sigmoide**, ilustrando como o modelo transforma combinações lineares das variáveis em probabilidades e onde se localiza o limiar de decisão de 0,5;

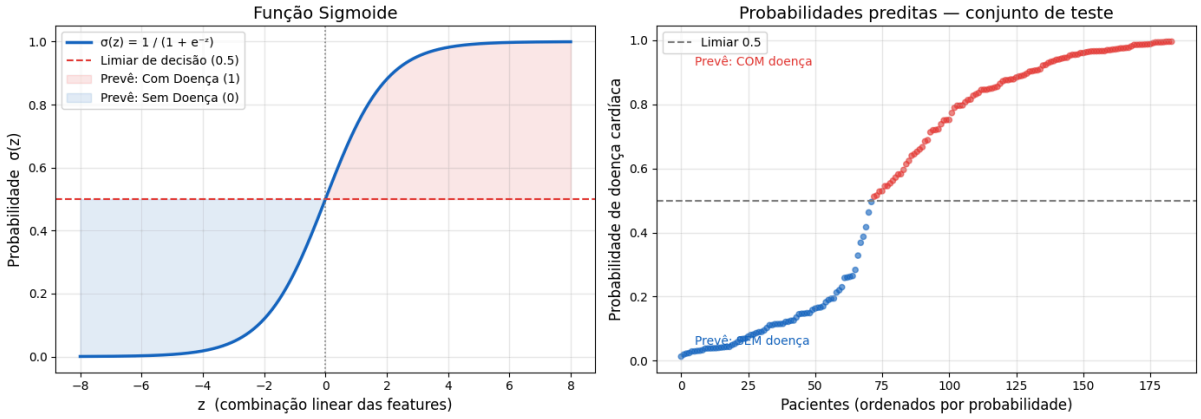

- **Gráfico de coeficientes**, exibindo o impacto de cada variável na predição — coeficientes positivos indicam aumento do risco de doença cardíaca, enquanto negativos indicam redução — o que confere interpretabilidade ao modelo e permite identificar os atributos mais relevantes clinicamente.

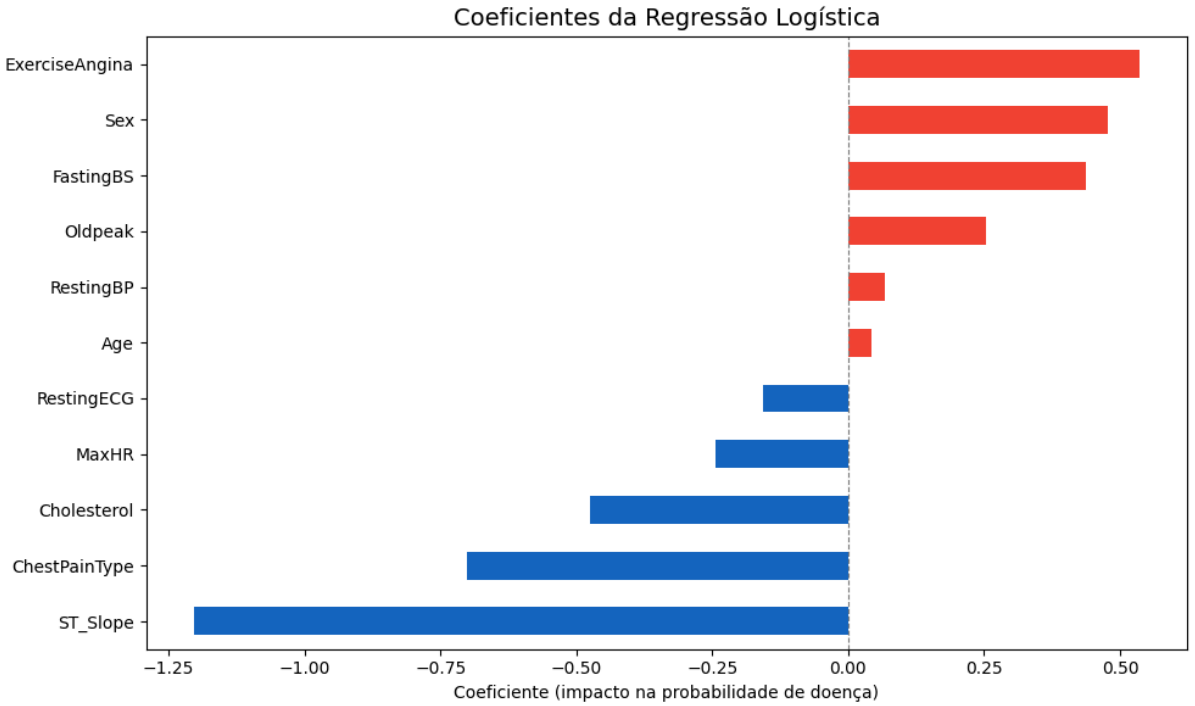

Resultados

Os experimentos realizados demonstraram que a metodologia baseada na Árvore de Decisão (utilizando o ID3) e a metodologia por Probabilidade de regressão logística apresentaram a mesma acurácia geral de 86,96% utilizando 20% para testes. Apenas de igualdade nessa métrica, a análise da matriz de confusão mostrou que os modelos não se comportaram de forma idêntica, pois houve diferenças na distribuição dos erros, ainda que pequenas, como segue na tabela abaixo.

Tabela Matriz de Confusão de ambas metodologias, coletadas do próprio código.

Matriz de Confusão	Árvore de Decisão	Probabilidade
Verdadeiro Positivo	64	65
Verdadeiro Negativo	96	95
Falso Positivo	13	7
Falso Negativo	11	17

Tabela de Relatório de Classificação - Metodologia de Probabilidade.

Relatório de Classificação	Precisão	Recall	F1 - Score	Suporte
Sem Doença	0.90	0.79	0.84	82
Com Doença	0.85	0.93	0.89	102
Average Macro	0.88	0.86	0.87	184
Average Weighted	0.87	0.87	0.87	184

Tabela de Relatório de Classificação - Metodologia de Árvore de Decisão.

Relatório de Classificação	Precisão	Recall	F1 - Score	Suporte
Sem Doença	0.84	0.86	0.85	77
Com Doença	0.90	0.88	0.89	107
Average Macro	0.87	0.87	0.87	184
Average Weighted	0.87	0.87	0.87	184

Na comparação entre as metodologias, observou-se que a Árvore de Decisão e a Probabilidade apresentam diferenças relevantes não apenas nas métricas de desempenho, mas também na forma como produzem e explicam suas previsões.

A Árvore de Decisão tende a se destacar pela interpretabilidade, pois permite visualizar com clareza quais atributos tiveram maior peso em cada decisão do modelo, o que é especialmente importante no contexto clínico.

Regressão Logística apresenta como vantagem a saída probabilística, permitindo estimar a chance de o paciente possuir patologia cardíaca, o que torna a análise mais refinada em casos limítrofes. Em termos práticos, enquanto a árvore pode capturar relações mais diretas e regras de decisão mais visíveis, a regressão logística tende a oferecer maior estabilidade estatística e uma interpretação mais consistente da influência de cada variável no resultado final.

Dessa forma, a comparação dos resultados deve considerar não apenas qual modelo acertou mais, mas também qual deles entregou maior equilíbrio entre acurácia, precisão, recall, F1-score e capacidade de interpretação para apoio à decisão médica.

Conclusão

Os objetivos propostos pelo grupo foram integralmente alcançados. Os modelos foram devidamente treinados, seguindo procedimentos metodológicos adequados, e apresentaram desempenho satisfatório em relação às métricas de avaliação previamente estabelecidas.

Destaca-se, contudo, um aspecto relevante observado durante a análise dos resultados, relacionado à acurácia dos modelos. Inicialmente, ambos apresentaram valores idênticos para essa métrica, o que gerou certa ambiguidade interpretativa por parte do grupo quanto ao desempenho comparativo entre eles. Entretanto, a realização de experimentos adicionais, com diferentes proporções na divisão dos dados especialmente no tamanho do conjunto de teste, evidenciou variações no desempenho dos modelos. Esses resultados indicam que, apesar da equivalência inicial observada, os modelos apresentam comportamentos distintos quando submetidos a diferentes configurações amostrais, demonstrando sensibilidade à forma de particionamento dos dados.

No contexto deste trabalho que se trata de uma condição de saúde crítica, a diferença nos erros dos nossos modelos tem um peso muito grande, já que a avaliação de desempenho não deve se limitar apenas à acurácia, mas também ao impacto prático de cada tipo de erro no cenário clínico. O estudo compara justamente essas duas abordagens para apoio ao diagnóstico de patologias cardíacas.

De forma geral, a metodologia por Probabilidade apresentou uma aplicação mais adequada do ponto de vista prático. Isso ocorre porque, em um contexto de saúde, um falso positivo é menos crítico do que um falso negativo. Em outras palavras, informar ao paciente que ele pode ter uma doença, mesmo que depois isso não seja confirmado, é um erro mais administrável do que afirmar que ele não possui a patologia quando, na realidade, ela está presente. Nesse ponto, o modelo probabilístico se sobressai, pois apresentou menor quantidade de falsos negativos, características que o torna mais seguro e mais coerente com uma lógica de prevenção e cuidado clínico.

Assim, embora os dois modelos tenham alcançado o mesmo percentual de acurácia, a metodologia por Probabilidade demonstrou melhor adequação para uso em apoio à decisão médica, justamente por reduzir a ocorrência do erro mais grave no contexto analisado.

Referências Bibliográficas

KÜHL, Niklas; SCHEMMER, Max; GOUTIER, Marc; SATZGER, Gerhard. **Artificial intelligence and machine learning**. *Electronic Markets*, [S. l.], v. 32, n. 4, p. 2235–2244, dez. 2022. DOI: 10.1007/s12525-022-00598-0. Disponível em: https://link.springer.com/article/10.1007/s12525-022-00598-0. Acesso em: 22 mar. 2026.

MIENYE, Ibomoiye Domor; JERE, Nobert. **A survey of decision trees: concepts, algorithms, and applications.** *IEEE Access*, [S. l.], v. 12, p. 1–12, jun. 2024. DOI: 10.1109/ACCESS.2024.3416838. Disponível em: https://ieeexplore.ieee.org/document/10562290. Acesso em: 22 mar. 2026.

GHAHRAMANI, Zoubin. **Probabilistic machine learning and artificial intelligence**. *Nature*, [S. l.], v. 521, p. 452–459, maio 2015. DOI: 10.1038/nature14541. Disponível em: https://www.nature.com/articles/nature14541. Acesso em: 28 mar. 2026.

OLOWE, Kehinde Josephine; EDOH, Ngozi Linda; ZOUO, Stephane Jean Christophe; OLAMIJUWON, Jeremiah. **Comprehensive review of logistic regression techniques in predicting health outcomes and trends**. *World Journal of Advanced Pharmaceutical and Life Sciences*, v. 07, n. 02, p. 016–026, 2024. DOI: https://doi.org/10.53346/wjapls.2024.7.2.0039. Disponível em: https://zealjournals.com/wjapls/. Acesso em: 28 mar. 2026.

ZABOR, Emily C.; REDDY, Chandana A.; TENDULKAR, Rahul D.; PATIL, Sujata. **Logistic Regression in Clinical Studies**. *International Journal of Radiation Oncology, Biology, Physics*, v. 112, n. 2, p. 271–277, 1 fev. 2022. DOI: 10.1016/j.ijrobp.2021.08.007. Disponível em: https://www.redjournal.org/article/S0360-3016(21)02646-8/fulltext. Acesso em: 28 mar. 2026.